

数学语言的向量剖面：从欧几里得到欧拉的跨文明定量扫描

作者：戴荣臻

ORCID: 0009-0005-7165-0080

日期：2026 年 4 月

摘要

人类是严重偏科的动物:感官体能落后大多数物种,但有一种能力被推到极致——焦虑的颗粒度特别细,细到需要精确知道"粮仓还能吃多少天"、"大堤还差几尺"、"孩子还有几岁成年"。理性是焦虑的减熵工具,语言把焦虑从个体脑中掏出来,数字把模糊的不安变成精确的数值。但自然语言多义、含混、不能精确复核,当焦虑精细到一定程度,自然语言就不够用了。**数学语言就是在这种压力下从自然语言中分化出来的一种特殊变体**,以牺牲表达的丰富性为代价,换取精确、可靠、可运算。

一个自然的问题是:各文明时代的文本里,数学语言的浓度如何?是少数精英经典的专属,还是渗透到了整个写作生态?科学革命前后这种分布发生了什么变化?这些问题在过去只能依靠科学史家对少数经典的定性解读。AI 文本嵌入模型的出现让这些问题**可以被定量地切开观察**。

本研究使用多语言文本嵌入模型 **BGE-M3** 对五个西方文明切片做了跨时代扫描:**希腊古典+希腊化** (339 件英译文本)、**罗马帝国** (659 件)、**文艺复兴** 1400-1600 (365 件)、**莱布尼茨时代** 1684-1734 (983 件)、**欧拉时代** 1740-1770 (1631 件),合计 3977 件作品,338 万段落。方法是:每个时代选一部标志性数学经典作为"向量中心"(希腊用欧几里得《几何原本》,文艺复兴用 Cardano《Ars Magna》,莱布尼茨用 Newton《Principia》,欧拉用 Newton《Opticks》),扫描该时代其他文本与中心的余弦相似度,以"相似度 ≥ 0.6 的

段落占比"作为一本书的数学语言浓度指标。基线测试显示:四个数学中心的自我命中率在 92.5% 到 98.5% 之间,说明方法能稳定识别数学语言这种文本风格。

结果呈现**两条清晰的演化曲线**。




图: 五切片数学语言浓度双曲线

纵向精英曲线(Top 5 均值):

希腊	罗马	文艺复兴	莱布尼茨	欧拉
61.1%	47.4%	41.6%	89.6%	90.9%

这条曲线呈 U 形——低点出人意料地不是罗马,而是文艺复兴。1600 年前后发生跃升,精英层从 42% 一跃至 90%,之后维持。

横向普及曲线(中位数):

希腊	罗马	文艺复兴	莱布尼茨	欧拉
0.31%	0.00%	0.00%	6.84%	3.12%

这条曲线在 1600 年之前**恒为零**——任何一个时代随机抽一本书,最可能看到的数学语言占比是 0。莱布尼茨时代首次突破 0,达到 6.84%。欧拉时代回落到 3.12%,但没归零。

两条曲线合起来揭示三个阶段:

- **孤峰时代(希腊-文艺复兴):**欧几里得、柏拉图、Cardano 孤立耸立,下面是大片的 0%。数学是少数人的事。
- **地层时代(莱布尼茨):**Newton / Huygens / Spinoza / Galileo / Bacon / Locke / Boyle / Hooke 形成一片连绵高地,Top 10 命中率全在 77% 以上。整个科学共同体开始共享一种语言。典型文本首次带上数学色彩。
- **稀释时代(欧拉):**Top 5 继续上升,但中位数腰斩。精英没消失,大众出版市场扩张得更快,科学文本的相对浓度被稀释。

本研究最重要的定量发现是**中位数从 0 到 6.84% 的跳变**。"科学革命"的传统叙事聚焦在牛顿、伽利略、笛卡尔等少数英雄;我们的数据揭示革命的另一面——不是 Top 5 变高(希腊的 Top 5 也不低),而是**底部的零被突破**。数学语言从孤峰变成了地层。

研究的主要局限包括:所有文本使用英译本(译者风格影响绝对值)、Gutenberg 和 Perseus 的数字化样本不等于历史真实阅读市场、方法识别文本风格而非数学思想(斯宾诺莎《伦理学》因模仿"几何方法"被判定为 89% 数学化即是典型案例)。这些局限使得本研究的结论应当主要以**相对关系**读取,不应外推为绝对命题。

研究意义在三处:(1)提出一套可复现、可扩展的跨文明定量文本分析方法;(2)以**中位数跳变**为核心,为"科学革命"提供了一个新的定量刻画;(3)为印刷时代的**稀释现象**提供定量证据。

关键词:数字人文、文本嵌入、科学革命、数学语言、BGE-M3、文本地层学

一、研究动机

1.1 焦虑如何变成了数字

人类是严重偏科的动物。感官和体能全面落后于其他动物,视觉不如鹰,嗅觉不如狗,奔跑不如狼。但人类有一个单科满分的能力:焦虑的颗粒度特别细。其他动物有恐惧,人类的焦虑却能精确到"粮仓还能吃多少天"、"大堤还差几尺"、"孩子差几岁成年"。

这种高分辨率的焦虑是理性的底色。人不是因为理性才去量化世界,是因为不量化就不安,才发展出理性。理性是焦虑的减熵工具。但焦虑在个体脑子里还只是模糊的不安,要变成改变世界的力量,需要两个外化通道:**语言**把焦虑从个体脑中掏出来变成可传递的信号,**数字**把焦虑从模糊变精确——"危险"变成"三头狼","冬天快来了"变成"还有四十天"。

语言有天生缺陷:多义、含混、无法精确、无法复核。"很多"不能用来修堤,"差不多"不能用来分粮,"早点"不能用来定历法。当焦虑精细到要修多高的堤、种多少亩地、派多少人守城,自然语言立刻不够用。于是数学语言应运而生——它是自然语言的一个分支演化出的特殊变体,牺牲了表达的丰富性,换来了不含糊的精确、可复核的可靠、可运算的推演。

几何原本、九章算术、Ars Magna、Principia——这些经典不是凭空出现的文化奇观,是焦虑演化到某个精度之后必然产生的结晶。一个文明积累的数学文本密度,本质上是那个文明焦虑颗粒度的化石记录。

1.2 我们想问的问题

一个自然的问题是:在欧几里得和荷马之间,其他文本分布在什么位置?亚里士多德《形而上学》、希波克拉底医学论文、修昔底德的历史、柏拉图的对话——它们离欧几里得多近、离荷马多近?这种"距离"能不能量化?

这个问题一旦被量化,就可以拓展到更大的范围。**不同时代的文本生态里数学语言的占比如何变化?**数学语言是只停留在少数精英经典里,还是在某个节点渗透到了一般写作?同一个时代内部,数学经典和大众读物之间的浓度差有多大?

如果能切开一个文明的某个时代,像地质学家切开地层一样,观察那个时代文本里数学语言的分布,就可以脱离"读起来像不像"的主观判断,得到一组定量数据。数据不能替代科学史学家的深入研究,但能提供一张**宏观地貌图**——哪些时代、哪些作者、哪些作品,在"数学语言浓度"这个指标上处于什么位置。

1.3 用 AI 嵌入模型做这件事的可行性

十年前这个问题没法做。要量化"两个文本之间的语言风格距离",需要一个能把任意文本映射到数值空间的工具。传统的词袋模型(如 TF-IDF)能部分做这件事,但它只看词频,不懂语义——"圆"和"circle"在它看来是两个完全不相关的词。

2018 年以来深度学习的文本嵌入模型(BERT、GPT、T5 的 embedding 层)解决了这个问题。它们把一段文本映射到高维向量空间,语义相近的段落在空间里也彼此相近。2024 年北京智源研究院发布的 BGE-M3 是这一代技术中对多语言、长文本支持最好的之一(详见第二章)。

本研究用 BGE-M3 做一件简单的事:把每个时代的数学经典编码成一个"向量中心",然后扫描该时代其他所有文本段落,看它们离这个中心多近。这就把"读起来多像数学"这个模糊的感觉,变成了一个可计算的数字。

1.4 研究问题

本研究回答三个层次的问题:

Q1(精英层):每个文明时代"最数学化"的几本书,数学语言浓度如何?随时间怎么变化?

Q2(普及层):每个时代的**典型书**(按中位数定义)有多少数学成分?数学语言是只在精英经典里活跃,还是已经扩散到大众文本?

Q3(稀释):在印刷术普及后(1500 年之后),随着出版市场扩张、大众读物(小说、游记、神学、传记)涌现,科学精英文本在整体文本生态中的相对密度是否被稀释?这种稀释是否有定量证据?

Q1 对应学界已有的科学史叙事——精英数学经典的演化;Q2 和 Q3 是本研究希望提出的新视角,它们需要**大规模、跨时代**的数据才能看到,恰好是 AI 嵌入模型能做的事。

1.5 人机协作

本研究由戴荣臻与 Anthropic Claude 共同完成。如果没有 AI 协助,这个工作量是难以想象的——扫描近四千本书、处理三百多万段文本、反复迭代方法细节,对一个没有实验室和团队的独立研究者来说,过去根本不具备可行性。

二、方法

2.1 BGE-M3:为什么选它

BGE-M3(BAAI General Embedding - Multi-lingual, Multi-functional, Multi-granularity) 是北京智源人工智能研究院于 2024 年 1 月发布的多语言文本嵌入模型。"BAAI"是智源的英文名缩写,"M3"指三个特性:多语言、多功能、多粒度。

模型的基本工作原理是:给它一段文本输入,它输出一个 **1024 维的向量**,这个向量代表了这段文本在一个"语义空间"中的位置。语义相近的文本,它们的向量在空间里距离也近;风格相异的文本,向量距离则远。这种映射关系是模型在大规模文本语料(数千亿 token)上通过对比学习训练出来的。

本研究选 BGE-M3 而不是其他嵌入模型,基于以下四个考虑:

一、多语言覆盖。BGE-M3 在 100 多种语言的语料上训练,对现代英语、中文、法语、德语都有较好支持,对拉丁、古希腊这类低资源语言也能给出基本可用的嵌入(虽然精度不如现代英语)。这对跨时代、跨文明的文本比较很重要。本研究所有文本统一使用英译本扫描(见 2.6),BGE-M3 的英语能力完全够用。

二、长输入支持。BGE-M3 的最大输入长度为 **8192 个 token**(约 6000 英文单词),而大多数同类模型只支持 512 token。这让本研究可以把书中的自然段落整段输入,不必强行切成小碎片,保持语义完整。

三、开源免费。模型权重在 HuggingFace 上公开,本研究在消费级显卡(NVIDIA GeForce RTX 5070,12GB 显存)上本地部署使用,无需向 API 付费。这对独立研究者非常友好。

四、输出向量紧凑。1024 维向量的计算开销适中,几千本书的扫描可在一两天内完成。更高维(如 4096 维)的模型(如 OpenAI text-embedding-3)在本研究的任务上带来的精度增益很小,但计算成本显著增加。

需要指出的是,BGE-M3 并不是专门为"风格分析"或"科学史"设计的工具。它是一个**通用的语义向量化工具**。我们利用的是它的一个副效应——"数学风格"的文本在它的向量空间里自然地彼此聚集——这个现象能否作为分析工具,需要通过结果本身验证(见 2.7 的基线测试)。

2.2 核心流水线

本研究的数据处理流程分四步,每一步都对应具体的代码操作:

第一步:切段。把一本书的全文切成若干自然段落。每段是分析的基本单元。

第二步:编码。把每段文字输入 BGE-M3,得到一个 1024 维向量。一本有 1000 段的书,会得到一个 1000×1024 的矩阵。

第三步:做中心。取一部代表性数学经典(如欧几里得《几何原本》),把它的所有段落向量**取平均**,然后**归一化为单位长度**,就得到一个 1024 维的"数学语言中心向量"。

第四步:算相似度。对待扫描的任意文本,把它的每段向量和中心向量做内积(余弦相似度,范围 -1 到 +1,通常在 0.3~0.9 之间)。每段得到一个相似度值,整本书就得到一组相似度分布,从中提取我们关心的统计指标(见 2.5)。

关键代码(Python,使用 `sentence-transformers` 库)如下:

```
from sentence_transformers import SentenceTransformer
import numpy as np

model = SentenceTransformer('BAAI/bge-m3')

# 做中心:以欧几里得《几何原本》为例
euclid_paras = split_into_paragraphs(euclid_text) # 约 5900 段
euclid_vecs = model.encode(euclid_paras,
                            normalize_embeddings=True, # 归一化为单位长度
                            batch_size=8)
center = euclid_vecs.mean(axis=0)
```

```
center = center / np.linalg.norm(center) # 再次归一化

# 扫描任意文本
target_paras = split_into_paragraphs(target_text)
target_vecs = model.encode(target_paras, normalize_embeddings=True, batch_size=8)
similarities = target_vecs @ center # 矩阵乘法=逐段求余弦相似度

# 统计
ratio_above_06 = (similarities >= 0.6).mean() # ≥0.6 的段落占比
max_sim = similarities.max() # 最高相似度
```

2.3 五个切片的设计

本研究选了五个西方文明切片。每个切片的"数学中心"选择,遵循一条铁律:每个时代用自己时代的数学经典,不跨时代共用。

切片	时段	数学中心	英译版本	段数
希腊古典+希腊化	约前 500 – 前 50	欧几里得《几何原本》	Heath 1908	5911
罗马帝国	约前 50 – 公元 400	欧几里得(借用)	同上	—
文艺复兴	1400 – 1600	Cardano 《Ars Magna》	Witmer 1968	291
莱布尼茨时代	1684 – 1734	Newton 《Principia》	Motte 1729/Global Grey 版	2024
欧拉时代	1740 – 1770	Newton 《Opticks》	Gutenberg 33504	529

为什么不跨时代共用同一个中心?因为数学语言本身在演化。古典希腊是演绎几何(欧几里得的"定义-公设-命题-证明"),文艺复兴是符号代数(Cardano 解三次方程),Newton 时代是几何化物理(Principia 的"定律-推论")和实验光学(Opticks 的观察记述),欧拉之后是分析学(级数、微分、积分)。如果用欧几里得一个中心扫所有时代,后世文本会因为"数学形态已变"而系统性地被判为低命中,造成误判。

为什么罗马借用欧几里得?因为罗马没有产出原创的纯数学经典——这本身是一个观察结论。罗马数学生态主要表现为对希腊数学的继承、注释、应用(维特鲁威建筑、老普林尼博物志、波伊提乌论本质)。用欧几里得作中心,恰好能量度这种继承的广度和衰减程度。

2.4 切段策略

我们按**自然段**切段,不按固定长度切。作者自己划分的段落是思考和表达的原始单元——一个定义是一段,一个证明是一段,一段叙事是一段。强行按 200 字或 5 句一刀切,会把完整的推理单元切碎。按自然段切,方法跟文本本身的逻辑结构对齐,并且可以天然覆盖散文、诗歌、戏剧、教科书等所有文本类型。

在此基础上设两条规则:

下限 30 字符:小于 30 字符的段作为噪声剔除,主要是章节标题、页眉页脚、TEI pointer 等无内容片段。

上限 1000 字符:超过 1000 字符的自然段按句号(‘.’、‘!’、‘?’ 后跟空白)二次切分,合并成不超过 1000 字符的小段。Gutenberg 上一些大部头有个别段长达 4000 字符以上,BGE-M3 对长段做注意力计算时显存占用随段长呈平方级增长,不设上限会导致推理不稳定。1000 字符对应约 150–200 个英文单词,两三个完整自然句,语义保留基本完整。阈值选 1000 而非更小,是为了**尽量少切自然段**——能不切的不切。

Perseus TEI XML(希腊、罗马切片)

Perseus Digital Library 的文本以 TEI 标准 XML 编码。散文段落由 `

` 标签界定,戏剧用 `` (说话人发言单元)和 `` (行),诗歌用 ``。抓取顺序是:先 `

` ,抓不到再 `` ,再抓不到按 `` 每 20 行合成一段(对应约 150–300 词,语义上近似一个完整场景或一段抒情)。

```
import re

def extract_tei(xml_path):
    text = xml_path.read_text(encoding='utf-8', errors='replace')
    for ent, rep in [('&mdash;', '-'), ('&aelig;', 'ae'), ('&amp;', '&'), ...]:
        text = text.replace(ent, rep)
    # 优先抓 <p> 散文段
    paras = re.findall(r'<p\b[^>]*>(.*?)</p>', text, re.DOTALL)
    if paras:
        return [clean(p) for p in paras if len(clean(p)) >= 30]
    # 抓不到 <p> 的,改抓 <sp> 戏剧发言
    sps = re.findall(r'<sp\b[^>]*>(.*?)</sp>', text, re.DOTALL)
    if sps:
        return [clean(sp) for sp in sps if len(clean(sp)) >= 30]
    # 再抓不到,按 <l> 诗行每 20 行合成一段
    ls = re.findall(r'<l\b[^>]*>(.*?)</l>', text, re.DOTALL)
    if ls:
```

```
lines = [clean(l) for l in ls if clean(l)]
return [' '.join(lines[i:i+20]) for i in range(0, len(lines), 20)]
```

Gutenberg 纯文本(文艺复兴、莱布尼茨、欧拉切片)

Project Gutenberg 的 txt 文件以 `\* START` 和 `\* END` 界定正文,自然段之间用双换行(`\n\n`)分隔:

```
def extract_gutenberg(txt_path):
    text = txt_path.read_text(encoding='utf-8', errors='replace')
    start = text.find('*** START')
    end = text.find('*** END')
    if start > 0:
        text = text[text.find('\n', start)+1 : end if end > 0 else len(text)]
    paras = re.split(r'\n\s*\n', text)
    result = []
    for p in paras:
        p = p.strip()
        if len(p) >= 30:
            result.extend(split_long(p))
    return result

def split_long(para, max_len=1000):
    """超过 1000 字符的自然段按句号二次切分"""
    if len(para) <= max_len:
        return [para]
    sents = re.split(r'(?<=[.!?])\s+', para)
    chunks, cur = [], ''
    for s in sents:
        if len(cur) + len(s) + 1 <= max_len:
            cur = (cur + ' ' + s).strip() if cur else s
        else:
            if cur: chunks.append(cur)
            cur = s
    if cur: chunks.append(cur)
    return [c for c in chunks if len(c) >= 30]
```

段长差异对命中率的影响

跨切片对比需要检验:不同切法出来的段长分布是否会系统性影响命中率?在希腊切片的 339 件文本上算平均段长与 `≥0.6` 命中率的 Pearson 相关系数,结果仅 **0.058**——几乎无相关。分组看:段长 > 500 字符的书平均命中率 2.8%,段长 ≤ 300 字符的平均 7.1%,短段反而略高。这说明 BGE 捕获的是内容的语义方向,不是段长本身。余弦相似度只看向量方向,BGE 编码时内部已归一化,段长的影响被吸收为向量模长的差异,归一化后消除,不影响方向。切段策略在统计上是鲁棒的。

2.5 指标

对每本书,记录三组数字:

- **max** — 该书所有段落中最高的相似度。反映"这本书最数学化的那段有多数学化"
- **ratio_06** — 该书相似度 ≥ 0.6 的段落占全书总段数的百分比。**这是本研究的核心指标**
- **p50, p95** — 该书所有段落相似度的中位数和 95 百分位,作为分布形态的补充参考

对每个切片,汇总所有书的 `ratio\_06` 得到分布,提取:

- **Top5 均值** — 该切片 `ratio\_06` 最高的 5 本书的平均值。反映**精英层浓度**
- **Top10 均值、Top1% 均值** — 精英层的更细粒度视角
- **简均** — 所有书 `ratio\_06` 的算术平均。反映切片总体浓度,但对极端值敏感
- **段加权均** — 按每本书的段数加权的平均。反映"所有段落"的平均命中率
- **中位数** — 该切片中间那本书的 `ratio\_06`。反映**典型书**的数字化程度

为什么要用多个指标。单看简均会被少数极端数学经典(如欧几里得 99%)拉高,误以为整个时代都很数学化。单看中位数会忽略精英层的存在(中位数为 0 不代表没有数学家)。**三个指标一起看,才能看出"精英层 vs 典型层"的分离程度**——这正是本研究想揭示的核心结构。

阈值 0.6 的选择。本研究用 `ratio\_06` 作为核心指标,阈值 0.6 是经验选择。在 BGE-M3 的余弦相似度分布里,0.5 以上已经"有一定语义相似",0.7 以上是"高度相似"。选 0.6 作为阈值,既不过于宽松(把大量泛泛相关的段都算进去),也不过于严苛(只有数学教科书才能被算入)。阈值敏感性分析见附录 B:阈值从 0.5 到 0.7 之间调整,各切片之间的相对排序保持稳定,只是绝对数值会整体升降。

2.6 关于英译本:统一语言层的必要性

本研究所有文本都使用英译本扫描。希腊文、拉丁文原文没有进入扫描流程。这是一个刻意选择,基于以下理由:

一、跨时代比较需要统一的语言层。五个切片的语言非常杂——希腊文、拉丁文、意大利文、英文、德文、法文(莱布尼茨时代很多重要作品是拉丁文、法文、德文)。如果每个切片用各自原文扫描,

向量空间会被语言差异主导,看不到跨时代的风格差异。统一到英译层,所有切片都在同一个语言生态中比较,差异就是真正的"文本风格"差异。

二、BGE-M3 对现代英语最强。模型在英语语料上训练量最大,嵌入精度最高。用英译本扫,相当于把所有时代的文本都投影到"BGE-M3 最擅长的坐标系"里。这损失了原文的语言信息,但收获了跨时代比较的可靠性。

三、代价是译本效应。我们测到的不是"原作者怎么用数学语言",而是"通过 19–20 世纪英译所呈现的文本风格"。19 世纪末以来,古典学者形成了一套相对稳定的"经典译法"(欧几里得用 Heath,荷马用 Murray 或 Rieu,西塞罗用 Loeb),这种译法本身携带维多利亚时代学术英语的风格。不同时代的文本经过这层"过滤"后,被我们观察到的差异,有一部分来自译者而非原作。

我们通过两个做法**部分**缓解译本效应:

- 1. **各切片的中心和被测文本尽量来自同代译者。**例如希腊切片的欧几里得中心(Heath 1908)和大部分希腊文本(Perseus 的 19 世纪英译)都是 19 世纪末到 20 世纪初的译本风格;Newton Principia 用 Motte 1729 英译;Cardano 用 Witmer 1968,在现代学术英语范围内。
- 2. **研究主要看相对关系而非绝对数值。**不同切片之间的 Top5 均值、中位数等指标的相对大小,比任何绝对值更可信。

2.7 基线验证:中心的自我命中率

为了检验"数学中心"是否捕捉到了真实的数学语言,我们做了一个基线测试:**把数学中心扫自己**。一本书如果风格内部一致,它对自己中心的平均相似度应该很高。

数学中心	自我扫描段数	`ratio_06` 自命中率
欧几里得《几何原本》(Heath)	5911	98.5%
Cardano《Ars Magna》(Witmer)	291	95.2%
Newton《Principia》(Motte)	2024	92.5%
Newton《Opticks》	529	96.6%

四本数学经典的自我命中率都在 92% 以上。这说明 BGE-M3 的向量空间内,数学文本确实有一个紧致的"簇",可以用一个平均向量代表。作为对照,我们把"希腊切片"里的荷马《伊利亚特》《奥德赛》

也取平均做了一个"史诗中心",它的自我命中率也达到 85% 以上——说明 BGE 确实在捕捉文本风格,但不同风格的簇是彼此分离的(史诗中心扫欧几里得的命中率 < 3%)。

这个基线测试表明,本研究使用的方法**能够稳定识别"数学语言"这种文本风格**,基本可靠。但这不意味着它能识别"数学思想"——它能识别"读起来像 Heath 译本的欧几里得的段落",不能识别"数学上有意义的段落"。这个区别在第四章讨论。

2.8 方法的边界与局限

本方法有三个必须预先声明的局限,在解读结果时必须记住:

一、测量的是"英译本的文本风格",不是原语言的数学实质。见 2.6。

二、Gutenberg 和 Perseus 的采样偏差。Gutenberg 的 Top 1000 不是"那个时代真实的阅读市场",而是"今天被数字化、被下载的样本"。Perseus 收录的英译是学术界挑选的经典译本,不是"罗马时期所有留存文本"。本研究的结果反映的是"**当代可得数字化英译文本的语言分布**",不等同于"历史上真实的阅读景观"。

三、方法不能识别"数学思想"。如果一本书讨论的是深刻的数学思想,但用的是文学式的语言(比如散文体的数学随笔),本方法会把它判为低命中。反之,如果一本书模仿了数学教科书的句式(比如斯宾诺莎《伦理学》"几何方法"那种"命题-证明"体裁),但内容是神学,本方法会把它判为高命中。这个局限在第四章的讨论里会用斯宾诺莎做案例说明。

三、数据与结果

3.1 五切片总览

五个切片的扫描结果汇总如下:

切片	本数	总段数	简均	段加权均	中位数	Top5 均	Top10 均
----	----	-----	----	------	-----	--------	---------

希腊(古典+化)	339	91,895	3.04%	10.81%	0.31%	61.14%	45.19%
罗马	659	119,995	1.61%	1.93%	0.00%	47.36%	35.47%
文艺复兴	365	432,870	0.88%	0.72%	0.00%	41.64%	23.71%
莱布尼茨时代	983	1,011,464	12.44%	12.89%	6.84%	89.58%	86.11%
欧拉时代	1,631	1,700,526	8.11%	7.60%	3.12%	90.86%	84.71%

所有指标单位均为百分比,表示一本书相似度 ≥ 0.6 的段落占比,或在该切片中的统计汇总值。

两条曲线可以从这张表里直接读出来:




图: 五切片双曲线与三阶段

纵向精英曲线(Top5 均):从希腊的 61.1%,经罗马 47.4% 和文艺复兴 41.6% 的低谷,跃升至莱布尼茨 89.6% 和欧拉 90.9%。

横向普及曲线(中位数):希腊、罗马、文艺复兴三个时代都接近 0%,莱布尼茨跳到 6.84%,欧拉回落到 3.12%。

下面逐切片看具体内容。

3.2 希腊切片:三家撑起的古典数学语言

希腊切片共 339 件英译文本,9.2 万段,以欧几里得《几何原本》为中心。Top 15 名单:

排名	作者	作品	段数	≥0.6 占比
1	Euclid	Elements(几何原本)	5911	98.5%
2	Plato	Parmenides(巴门尼德)	41	70.7%
3	Aristotle	Metaphysics(形而上学)	1779	63.0%
4	Plato	Timaeus(蒂迈欧)	106	38.7%
5	Plato	Sophist(智者)	779	34.8%
6	Hippocrates	Nutriments	53	30.2%
7	Aristotle	Eudemian Ethics	611	30.1%
8	Plato	Philebus	781	29.7%
9	Plato	Statesman	600	29.3%
10	Plato	Epinomis	41	26.8%

希腊切片呈现“一主三副”的结构。欧几里得《几何原本》以 98.5% 的近乎全段命中独占最高位,是中心本身,近似于 100% 的自我参照。它和第二名拉开将近 30 个百分点。第二到第十名几乎全部被柏拉图(5 部入榜)和亚里士多德(2 部)占据,另加希波克拉底(医学观察)一部。

值得注意的是柏拉图的位次:《巴门尼德》70.7%,《蒂迈欧》38.7%,《智者》《菲利布》《政治家》都在 29% 以上。柏拉图并不是数学家,但他的对话录以定义、辩证、分类为核心手段,语言上的“紧致”特征恰好被 BGE 捕获为接近欧几里得风格。这是一个重要的信号:**数学语言并非只存在于数学文本,它在哲学中以相同的句式结构出现。**

希腊切片的中位数是 0.31%,接近 0。这意味着 339 件文本中一半以上的书命中率低于 0.31%——史诗、戏剧、历史、演说辞、诗歌这些主流体裁几乎完全不沾数学语言。**希腊古典的数学化是彻底的“孤峰结构”:**顶上是欧几里得,下面是柏拉图和亚里士多德的哲学,再往下是一大片 0%。

3.3 罗马切片:无原创但传承未断

罗马切片共 659 件文本(拉丁 207 件 + 罗马期希腊语 412 件),12 万段,仍以欧几里得为中心。Top 15:

排名	作者	作品	段数	≥0.6 占比
1	Boethius	Quomodo Substantiae(论本质)	15	93.3%
2	Plutarch	Procreation of the Soul	54	44.4%
3	Plutarch	Of Fate	20	35.0%
4	Plutarch	De E apud Delphos	28	32.1%

5	Plutarch	Face in the Moon	69	31.9%
6	Lucretius	De Rerum Natura(物性论)	490	29.6%
7	Boethius	De Trinitate	28	25.0%
9	Vitruvius	De Architectura(建筑十书)	755	19.9%
15	Galen	On the Natural Faculties	259	13.5%

罗马切片的 Top 5 均值 47.4%,比希腊的 61.1% 低 14 个百分点。关键观察是:**罗马没有原创的纯数学经典**,Top 1 波埃修斯《论本质》的 93.3% 是一篇极短的哲学论文(仅 15 段),且波埃修斯(480-524)其实已属西罗马灭亡后的转折期人物。除他之外,**第二到第十五位几乎被一人主导——普鲁塔克**,他在伦理论文集(Moralia)里的新柏拉图主义篇章频繁出现在榜单上(7 次)。

这个数据说明了罗马数学生态的真实面貌:它不产出欧几里得式的原创数学经典,但通过**罗马帝国境内用希腊语写作的知识人**(普鲁塔克、盖伦)和**晚期拉丁语哲学家**(波埃修斯),延续了希腊数学哲学的风格。卢克莱修《物性论》29.6% 是一个有趣的个案——一部完全用诗体写成的伊壁鸠鲁原子论长诗,在 BGE 眼里仍然有近三成段落接近欧几里得语言。维特鲁威《建筑十书》19.9% 代表的是"应用量化"的实用传统。

但中位数是 0.00%——整个罗马文本生态里,一半以上的书完全不沾数学。罗马和希腊一样是孤峰结构,只是顶峰更矮、更分散。

3.4 文艺复兴:更瘦的孤峰

文艺复兴切片共 365 本 Gutenberg 英译,43 万段,以 Cardano 《Ars Magna》为中心。Top 15:

排名	作者	作品	段数	≥0.6 占比
1	Cardano	Ars Magna(大术)	291	95.2%
2	Dürer	Of the Just Shaping of Letters(字母几何)	122	48.4%
3	Record	The Path-Way to Knowledge(知识之路)	621	31.2%
4	Dee	Mathematicall Praeface(数学序言)	446	20.2%
5	(Gutenberg 工具索	—	68	13.2%

	引,噪声)			
6	Caxton	Dialogues in French and English	540	8.0%
7	Leonardo	Notebooks Vol. 1	1927	6.7%
8	Leonardo	Treatise on Painting	1722	5.8%
9	Agricola	De Re Metallica(冶金)	4379	4.6%

文艺复兴是五切片中 Top 5 均值最低的(41.6%),**比罗马还低**。但这个切片有意思在另一处:**Top 1 到 Top 4 完全是一个小型数学共同体**——卡尔达诺的代数、丢勒的字母几何(用圆规直尺设计罗马字母比例)、罗伯特·雷科德的英国第一本算术教科书、约翰·迪伊为欧几里得英译写的序言。四个人都是 16 世纪人,彼此隔着短短几十年,都是用数学工具重新组织已有的艺术或教育材料。

但第 5 名以后迅速跌到 8% 以下。达芬奇的笔记、阿格里科拉的《冶金》、乔叟、蒙田——文艺复兴最著名的人物,在这张榜单上命中率都不到 7%。Agricola 的《冶金》4.6% 尤其说明问题:这本书有大量度量、比例、工艺描述,但它的文本结构是叙事-操作混合体,不像欧几里得或卡尔达诺那样纯粹。

文艺复兴的图像是一座更瘦的孤峰:顶上的卡尔达诺孤立高耸,下面四个小山头,再下面是大片的神学、文学、历史、游记。中位数 0.00%。**它并没有形成一个可与希腊媲美的"数学文化圈"**——**尽管已经开始有数学教育(Record)、数学工艺(Dürer)和数学哲学(Dee)的萌芽**。

3.5 莱布尼茨时代:科学共同体的涌现

莱布尼茨时代切片共 983 本 Gutenberg 英译,100 万段,以 Newton 《Principia》为中心。这个切片发生的事情与前三个时代完全不同。Top 15:

排名	作者	作品	段数	≥0.6 占比
1	Newton	Principia Mathematica	2024	92.5%
2	Newton	Opticks	891	90.6%
3	Huygens	Treatise on Light(光论)	422	90.3%
4	Spinoza	Ethics — Part 1	197	89.3%
5	Pemle	A Briefe Introduction to Geography	182	85.2%
6	Spinoza	Improvement of the Understanding	208	84.1%
7	Berkeley	Principles of Human Knowledge	328	83.8%

8	Pemberton	A View of Sir Isaac Newton's Philosophy	1249	83.6%
9	Whiston	Course of Mechanical, Magnetical, Optical Lectures	313	81.5%
10	Spinoza	Ethics — Part 5	151	80.1%
11	Galileo	A Discourse	533	79.7%
12	Spinoza	Ethics(合集)	1255	79.4%
13	Bacon	Novum Organum	1013	78.9%
14	Hobbs	Finding Longitude	66	78.8%
15	Huygens	The Celestial Worlds Discover'd	265	77.0%

这张表最直观的信号是:Top 15 的命中率全部在 77% 以上,下限比希腊/罗马/文艺复兴的上限还高。

Top 5 均值 89.6%,Top 10 均值 86.1%——这不是"孤峰"分布,而是一个完整高地。

细看榜单内容:牛顿 2 部、惠更斯 2 部、斯宾诺莎 4 部、伽利略、培根、伯克利、洛克、帕姆伯顿、惠斯顿——**这就是后来被科学史写进"科学革命"章节的那一批人**。他们的作品在 BGE 空间里彼此相近,说明这个时代产生了一种**跨作者、跨学科的共同文本风格**。伽利略写的是运动学,斯宾诺莎写的是伦理学,洛克写的是认识论,但他们都用了近似欧几里得-牛顿的语言结构(定义-公理-推论-证明)。

特别值得注意的是 Pemble、Pemberton、Whiston:这三位在 Gutenberg 今天的下载量排名是 840、355、687,属于"今天基本没人读"的作者。但在 17-18 世纪他们都是牛顿思想的传播者——Pemberton 写过官方认可的牛顿哲学导论,Whiston 是牛顿在剑桥的继承人。**他们的命中率和牛顿同级**,这就是"科学共同体"的直接证据:不是几个天才高耸,而是一群人在共享一套语言。

莱布尼茨切片的中位数是 6.84%。这是一个**质变信号**。在前三个切片里,中位数都是 0 或接近 0,意味着典型书根本不含数学语言;这里中位数首次明显大于 0,意味着 **983 本书的中间那一本都能找到 6-7% 的段落接近牛顿的风格**。数学语言从孤峰变成了地层——精英仍在顶端,但整个文本生态的"背景浓度"上升了。

3.6 欧拉时代:精英高位与大众稀释并存

欧拉时代切片共 1631 本,170 万段,以 Newton《Opticks》为中心。Top 15:

排名	作者	作品	段数	≥0.6 占比
1	Berkeley	Essay Towards a	243	97.1%

		New Theory of Vision(视觉新论)		
2	Newton	Opticks	891	96.2%
3	Huygens	Treatise on Light	422	91.2%
4	Penrose	A Treatise on Electricity	98	85.7%
5	Goethe	Theory of Colours(颜色论)	1498	84.0%
6	Boyle	Experiments Touching Colours	909	83.9%
7	Hooke	Micrographia(显微图谱)	1621	81.9%
8	Berkeley	Principles of Human Knowledge	328	77.7%
9	Grew	The Anatomy of Vegetables	392	74.7%
10	Pemberton	Newton's Philosophy	1249	74.5%
11	Huygens	Celestial Worlds	265	73.6%
12	Franklin	Experiments on Electricity(电学实验)	300	72.0%
13	Boyle	Sceptical Chymist	777	71.8%
14	Grew	Anatomy of Plants	2350	71.1%
15	Whiston	Mechanical Lectures	313	69.6%

欧拉切片的 Top 5 均值 90.9%,**比莱布尼茨的 89.6% 还略高**。这批名单的内容也比莱布尼茨更丰富——光学(Newton/Huygens/Berkeley)、色彩理论(Goethe/Boyle)、显微(Hooke)、电学(Franklin/Penrose)、植物解剖(Grew 2 部)全都齐备。**18 世纪前中叶的自然哲学在语言风格上延续并扩展了 17 世纪的科学共同体。**

榜单再往后(Top 20 内)还有 Hume 《人性论》69.3%、Kant 《未来形而上学导论》64.1%——这两位哲学家在 BGE 眼里具备接近 Opticks 的语言紧致度,说明**启蒙运动的哲学主流继承了科学文本的风格**。

但这个切片真正重要的信号在中位数:欧拉时代的中位数是 3.12%,比莱布尼茨的 6.84% **少了一半以上**。

对比本数:莱布尼茨 983 本,欧拉 1631 本,增长 66%。对比总段数:101 万 → 170 万,增长 68%。也就是说,欧拉时代的**文本总量在爆炸性扩张**,但扩张出来的大多数新书不是数学化的。**精英科学家没有消失**(Top 5 更高了),但他们在整个文本生态里的**"相对浓度"下降了一半**。

这就是我们在研究问题 Q3 里提出的"稀释"现象的定量证据。欧拉时代正值欧洲印刷工业成熟、小说体裁兴起、旅行游记和布道文集大众化的时期。新涌现的大量出版物属于小说、传记、游记、神学、戏剧,它们把"一本书的期望命中率"拉下来了——但没有把精英顶端拉下来。

3.7 两条曲线并置

把五个切片的核心数据画在一起,能看到两条非常清晰的曲线。




图: 五切片双曲线

纵向精英曲线(Top 5 均值):

希腊		61.1%
罗马		47.4%
文艺复兴		41.6%
莱布尼茨		89.6%
欧拉		90.9%

横向普及曲线(中位数):

希腊		0.31%
罗马		0.00%
文艺复兴		0.00%

莱布尼茨	6.84%
欧拉	3.12%

纵向曲线告诉我们:数学精英经典在 1600 年前是一条从高位下滑的曲线(希腊 61% → 罗马 47% → 文艺复兴 42%)——不是绝对衰退,而是"找不到像欧几里得那样能够独立支撑整个数学语言风格的经典"。1600 年后急速跃升至接近满分(90%),一直维持。

横向曲线告诉我们:整个文本生态的数字化程度,在 1600 年前**恒为零**——任何一个时代,如果你随机抽一本书,最可能看到的数学语言占比是 0。1600 年后,这个数字第一次变得明显大于零,在莱布尼茨时代达到峰值 6.84%,然后在欧拉时代被新涌现的大众读物稀释回 3.12%。




图: 五切片分层柱状图

分层柱状图更直观地展示了这个变化。希腊切片 63.4% 的书在 "<1%" 区间(几乎不沾数学), 罗马 74.4%, 文艺复兴最极端——**91.0% 的书命中率低于 1%**, 也就是说 365 本里 332 本几乎不沾数学。到了莱布尼茨时代, "<1%" 区间骤降至 16.7%(164 本), 而 "1-5%" 和 "5-20%" 两个中层区间合起来占了 66%——**大量普通书进入了"有一点数学味"的状态**。欧拉时代这个结构开始回潮: "<1%" 上升到 24.3%(397 本), "1-5%" 区间也扩大到 37.4%(610 本), 中层的 "5-20%" 被稀释。精英层(≥50%) 在莱布尼茨的 5.1%(50 本) 和欧拉的 2.9%(48 本) 都保持住了。

横向曲线的意义大于纵向曲线。纵向曲线告诉我们少数精英在做什么;横向曲线告诉我们**整个社会的写作生态**在做什么。"科学革命"的常见定义是围绕 Newton、Galileo、Boyle 等几位英雄人物展开的——但在我们的数据里,真正的质变不在 Top 5(前三个时代的 Top 5 也都不低),而在**中位数第一次从 0 跳到 6.84%**。数学语言第一次从孤峰变成了地层。

3.8 一些细节

这里记录几个在数据扫描中出现的具体观察,它们或者支持主结论、或者暴露方法局限,都值得单独列出。

斯宾诺莎问题。Spinoza《伦理学》五个部分在莱布尼茨切片里全部进入 Top 12,命中率 73-89%。但斯宾诺莎讨论的是神学与伦理,不是自然科学。他用的是"几何方法"——模仿欧几里得的"定义-公理-命题-证明"体例写神学。**BGE 抓到了这个外壳,把他判为高度数学化。**这是我们方法的一个显性局限:**方法识别的是文本风格,不是数学思想。**在讨论章会详细展开这一点。

Goethe《颜色论》。歌德的《颜色论》在欧拉切片 Top 5,84%。歌德著名地反对牛顿的光学,从哲学-现象学立场批评牛顿。但他在文本风格上完全延续了 Opticks 的"观察-记录-归纳"语言结构。**内容反对,风格同源**——BGE 捕获的是后者。

Pemberton / Whiston / Pemble。三位在莱布尼茨切片 Top 15 里出现,今天下载量排名都在 Top 300 之外(Pemberton rank 355, Whiston 687, Pemble 840)。这说明**今天的 Gutenberg 下载排名不能代表 17-18 世纪的真实学术影响力。**使用下载排名作为"历史重要性"代理的研究应该警惕这一点。

文艺复兴 Top 2 的丢勒。Dürer《字母的正确塑造》命中 48.4%,远高于文艺复兴的其他非数学作品。这本书是丢勒用圆规和直尺几何作图法推导罗马字母比例的技术论文。它作为视觉艺术作品在艺术史上常被提及,但作为**数学文本**的身份较少被强调。我们的方法把它从数百本文艺复兴书中挑出来放在第二位,算是一个小的发现。

Berkeley《视觉新论》以 97.1% 在欧拉切片登顶,甚至高于 Newton《Opticks》本身(96.2%)。伯克利的《视觉新论》是一部从哲学角度讨论"人如何通过视觉感知距离与大小"的著作,使用了大量几何-光学推理。它在 BGE 眼里比 Opticks 本身"更像 Opticks",说明他深度内化了牛顿的语言。

四、讨论

4.1 三阶段的文本地层学

把两条曲线合起来,我们得到一个三阶段的文明文本地层学:

第一阶段:孤峰时代(古典-文艺复兴)。希腊、罗马、文艺复兴都是孤峰结构——精英经典高高耸立,大众文本完全不沾数学。希腊的孤峰最高(欧几里得+柏拉图+亚里士多德三巨头),罗马的变瘦(无原创经典,靠普鲁塔克和波埃修斯支撑),文艺复兴的更瘦(Cardano 独木难支,下面只有 Dürer/Record/Dee 几个小山丘)。这三个时代的中位数都是 0——数学是少数人的事,整个社会的文本生态与数学无关。

第二阶段:地层时代(莱布尼茨)。中位数第一次从 0 跳到 6.84%,精英层从 40% 跃升到 90%。这两个数字同步跳变,说明发生的不是"又多了几个数学家",而是**整个科学与哲学共同体开始共享一种新的语言风格**。Newton/Huygens/Spinoza/Galileo/Bacon/Locke/Boyle/Hooke——这些人不再是孤立的山峰,而是一片连绵的高地。数学语言从"几本书里的特殊方言"变成了"一代知识人的普通话"。这才是"科学革命"在文本层面的真实形态。

第三阶段:稀释时代(欧拉及以后)。精英层继续上升(Top 5 均 90.9%),但中位数腰斩(6.84% → 3.12%)。这个双向运动揭示了印刷时代的一个特殊现象:**出版市场扩张得比科学共同体快**。新涌现的大量出版物——小说、游记、布道文、传记、戏剧——不数学化,它们淹没了科学精英在整体文本中的相对比例。**精英没变少,大众变多了。**

三个阶段对应着数学语言与社会文本生态三种不同的关系:孤立,浸润,被稀释。

4.2 "科学革命"的另一种刻画

"科学革命"是科学史中的核心概念,但不同学者的界定不同。Koyré 强调宇宙观从封闭到开放的转变,Dijksterhuis 强调机械论世界观的兴起,Butterfield 强调方法论的突破(数学化+实验)。这些刻画都聚焦在少数核心文本(Copernicus, Galileo, Descartes, Newton)。

我们的数据提供了**另一个刻画维度**:科学革命在文本层面的标志不是精英层变高——希腊的精英层已经很高(61%)——而是**中位数从 0 变成了正数**。

希腊有欧几里得和柏拉图,但"一个希腊人随手拿起一本书读",读到数学语言的概率是 0。莱布尼茨时代"一个欧洲知识人随手拿起一本书读",读到数学语言的概率变成了 6.84%。**这个数字的 0 和非 0 之间的差别,比任何纵向曲线的抬升都更像一场革命。**

这不是要替代科学史的英雄叙事,而是补充一个侧面:革命不只是少数天才的创造,也是一个共同体语言的形成。当 Newton 写出 Principia,它能立刻被同代人(Huygens, Locke, Spinoza, Bacon)用相近的语言结构阅读、讨论、发展——这种"可被同代人共同处理"的状态,恰恰是孤峰时代不具备的。

4.3 罗马数学:不是衰退,是"无原创经典的延续"

我们的数据为罗马数学的历史评价提供了一个细致的视角。

传统叙事常说"罗马数学衰退了",罗马没有产生欧几里得、阿基米德、阿波罗尼奥斯那样的原创数学家。这是事实。但**"罗马没有原创数学经典"不等于"罗马没有数学语言"**。

我们的 Top 15 里,9 个位置属于普鲁塔克——一个讨论伦理、宗教、神话的希腊语散文家。他的《伦理论集》里讨论宇宙灵魂、命运、德尔菲的 E、月亮的脸的那些篇章,命中率 20-44%,**这些文本使用的是柏拉图-毕达哥拉斯传统的数学哲学语言**。加上波埃修斯 93%、卢克莱修 30%、维特鲁威 20%、盖伦 14%,我们看到的不是"数学不见了",而是**"数学从独立经典回到了嵌入式存在"**——它嵌在哲学讨论、应用工程、医学理论、科普诗歌里。

罗马中位数为 0 进一步说明这种嵌入是表层的。罗马没有像希腊那样形成可持续的数学教育和研究共同体(希腊还有亚历山大图书馆和博物馆),数学变成了少数博学者的私人修养。等到波埃修斯在 6 世纪初翻译亚里士多德和写《论本质》时,他已经是一个在被夷平的废墟上孤独整理遗产的人。

4.4 文艺复兴:精英更瘦,大众依旧

文艺复兴切片的 Top 5 均 41.6%,低于希腊的 61.1% 和罗马的 47.4%。这初看反直觉——文艺复兴不是"数学重新兴起"的时代吗?

我们的数据显示:**卡尔达诺《Ars Magna》是孤立的**。它在文艺复兴切片里 95.2%,断崖式高于第二名丢勒的 48.4%。再往后是 31%、20%、13%,跌落非常快。这不是"文艺复兴数学共同体"——这是"卡尔达诺+三个边缘人物"。

对比莱布尼茨切片,Top 1 到 Top 15 的命中率从 92.5% 到 77%,几乎是一个平原;文艺复兴 Top 1 到 Top 15 从 95.2% 到 2.8%,像悬崖。**卡尔达诺没有同代人——至少在 Gutenberg 数字化的 365 本书里,没有能与他语言相通的人**。丢勒(艺术)、Record(教育)、Dee(哲学)是在"边缘应用数学"的领域,不是卡尔达诺代数意义上的同行。

文艺复兴在科学史上被视为"承前启后"的关键时代,常和哥白尼、维萨里、伽利略前期相关联。但我们这个切片的时间窗是 1400-1600,**只到伽利略出生前后就截止了**。真正的"共同体"形成要等到下一个切片——伽利略、开普勒、笛卡尔、惠更斯、牛顿这批人——也就是莱布尼茨切片。从这个角度看,文艺复兴切片的"瘦孤峰"图像是合理的——**科学革命还没发生**。

4.5 方法局限的再反思

第二章已经列出了三条方法局限。通过第三章的具体结果,我们可以把这些局限的具体表现谈得更清楚。

斯宾诺莎效应。斯宾诺莎《伦理学》在莱布尼茨切片连续占据 Top 4/6/10/12,命中率 79-89%。他讨论的是上帝、心智、情感、伦理,但他用"几何方法"——每一节都是"定义 → 公理 → 命题 → 证明 → 推论"。BGE 把这个外壳识别为高度数字化。

这是一个典型的**形式欺骗内容**的案例。如果研究者不了解斯宾诺莎,会认为他是一个重要的数学哲学家。实际上他的数学形式是**借用的**,内容几乎完全是形而上学。

这里要指出的是:**这个识别结果从某个角度看并不是错的**。斯宾诺莎选择用几何方法写神学,本身就是一个**文化信号**——他认为最严谨的真理陈述方式是欧几里得式的。这种形式选择的流行(Wolff, Christian Wolff, 等人都写过"几何方法"的哲学),恰恰是"数学语言地层化"的一种表现:数学语言的**形式权威**外溢到了非数学领域。

所以我们的数据**同时捕捉了两件事**:真正的数学化(Newton)和数学形式的文化外溢(Spinoza)。在讨论 Q1 "精英层浓度"时这两者要区分;但在讨论 Q2 "数学语言如何渗透到大众文本"时,两者都是证据。

英译本效应。所有数据都依赖英译本。希腊文、拉丁文、意大利文、法文、德文的原作都通过 19-20 世纪英译被投射到我们的向量空间。译者的风格会影响命中率。举例:卢克莱修《物性论》29.6%用的是 Munro 1867 英译,Munro 是一位维多利亚时代的剑桥学者,倾向于用标准学术英语处理卢克莱修的诗体原文,这可能拉高了命中率。如果换成更现代、更口语化的 Stallings 2007 英译,结果可能不同。

这是一个系统偏差,我们目前没有办法完全消除。减缓办法是**同一切片内尽量用同一代译本,且主要看相对关系而不是绝对值**。后续研究如果能直接扫描原语言文本(用针对古希腊文、拉丁文专门训练的嵌入模型),结果会更可信。

Gutenberg/Perseus 采样偏差。我们的五切片文本来自两个数字化库:Perseus(古典语言)和 Gutenberg(现代语言)。两个库都不是"那个时代真实的阅读景观"——它们是 20-21 世纪被挑选和数字化的样本。

这对本研究的主结论影响如何?我们的主结论是**相对性的**:莱布尼茨中位数 6.84% vs 欧拉 3.12%,这是同一个数据库(Gutenberg)内不同时代的对比。两个时代面临的"被数字化"概率应该大致对等(Gutenberg 选书标准是"有历史价值且版权过期"),**相对关系比绝对值可信**。但我们不能说"1700 年欧洲人随手读到数学书的概率是 6.84%"——那个绝对值是数字化样本的统计,不是历史真实。

五、结论与未来工作

5.1 主要发现

本研究扫描了 3977 件英译作品、338 万段文本,跨越约 2200 年的西方文明史。主要发现:

发现一:纵向精英曲线呈 U 形。Top 5 均值从希腊 61% 经罗马 47% 文艺复兴 42% 跌到谷底,然后在莱布尼茨时代跃升至 90%,欧拉时代稳定在 91%。U 形的底部不是罗马,而是文艺复兴——这颠覆了"文艺复兴即数学复兴"的直觉印象。真正的数学复兴要等到 17 世纪后半叶。

发现二:中位数首次跳变发生在莱布尼茨时代。希腊、罗马、文艺复兴三个时代的中位数都接近 0——典型文本完全不含数学语言。莱布尼茨时代中位数跳到 6.84%,欧拉回落到 3.12%。这是本研究最重要的定量发现。"科学革命"在文本层面的标志不是精英层变高,而是中位数从 0 变成正数。数学语言从孤峰变成了地层。

发现三:印刷时代有定量的稀释效应。欧拉时代 Top 5 均值比莱布尼茨略高(90.9% vs 89.6%),但中位数腰斩(3.12% vs 6.84%),总文本量增长 66%。**精英科学家没有消失,但他们被快速扩张的大众出版市场在相对浓度上稀释了。**这个现象在下一步需要扩展到更长的时间尺度(19 世纪、20 世纪)验证。

发现四:罗马不是数学衰退,是没有原创经典。罗马 Top 15 里 9 位是普鲁塔克——一位用希腊语讨论柏拉图主义、命运、宇宙灵魂的散文家。罗马没有欧几里得式的新经典,但通过嵌入式的哲学和应用,延续了希腊数学的语言传统。"衰退"的叙事不够准确。

发现五:数学语言的形式权威外溢。斯宾诺莎《伦理学》用"几何方法"写神学,BGE 把它识别为高度数学化(89%)。这不是方法错误,而是一种文化现象——数学的形式权威被当代知识人主动借用,说明数学语言已经成为"严谨陈述"的范式。这种外溢本身就是"地层化"的表现。

5.2 研究的边界

本研究的所有结论都依赖三层前提:

3. **样本是 Gutenberg 和 Perseus 的数字化文本,不是历史上真实的阅读景观**

4. **文本统一使用英译本扫描**,译者风格影响绝对值
5. **方法识别的是文本风格,不是数学思想**

在这三层前提下,**相对关系(切片之间的高低、精英与中位数的差距)比绝对值可信**。读者应当在这个边界内使用本研究的结论,不应外推为"某朝代某地区人均数学素养"之类的更强命题。

5.3 后续方向

本研究是一个更长期计划的第一块。后续可以展开的方向:

方向一:填补中世纪切片。本研究的罗马切片结束于公元 4-6 世纪,文艺复兴切片从 1400 年开始,中间有约 1000 年空白。这段时间欧洲的数学发展由伊斯兰世界中介(al-Khwarizmi, al-Khayyam)和晚期拜占庭承载。扫描 Fibonacci《Liber Abaci》、Oresme、Bradwardine 等中世纪文本,能填补这个空白。

方向二:中文切片独立研究。本研究刻意不把中文数学文本(九章算术、数书九章、四元玉鉴)加入对比——因为它们与欧洲切片使用不同的语言、不同的数学范式、不同的社会结构,强行放到同一张图上对比会产生伪关联。正确的做法是单独做一个中文切片,用九章算术作为中心,扫描中国历代文本,画出一条独立的曲线,再与欧洲曲线做结构比较而非数值比较。

方向三:向后延伸到 19-20 世纪。欧拉时代的稀释是起点还是终点?随着 19 世纪大学科学体制化、20 世纪科学论文作为独立体裁的形成,精英与大众的分化会进一步加深还是重新汇聚?这需要我们继续扫描 Gutenberg 19-20 世纪部分。

方向四:向连续语言延伸。本研究的更大框架把语言沿"离散-连续"谱划分为四个阶段:自然语言 → 数学语言 → 机器语言(代码)→ AI 高维连续语言(嵌入向量本身)。本研究切的是第一阶段到第二阶段的过渡。未来可以用同样的方法切"机器语言"(GitHub 代码语料)和"AI 连续语言"(大模型生成文本)的剖面,看四个阶段之间的过渡是否都有"孤峰-地层-稀释"这种文本地层学结构。

5.4 数据与代码开放

本研究全部数据和代码开放:

- **五个切片的扫描结果 JSON**(5 个文件,每本书的 max / ratio_06 / p50 / p95 等指标)

- **中心向量 npy 文件**(4 个,欧几里得、Cardano、Newton Principia、Newton Opticks)
- **扫描脚本**(Python,使用 sentence-transformers 库,可在消费级显卡上复现)
- **作者-作品映射表**(Perseus 希腊/拉丁,Gutenberg 按时代筛选的 rank 表)

GitHub 仓库:(待发布)

欢迎任何使用、验证、扩展。如果你用这个方法扫了新的切片或发现了新的结构,请告诉我们,我们会把它整合进更大的地层图。